

08. Token e Context Window

Manuale: Introduzione ai Token e alla Finestra di Contesto nell'Intelligenza Artificiale

Capitolo 1: Cosa sono i Token?

Nel contesto dell'Intelligenza Artificiale (IA), un token è un'unità di dati che rappresenta un'informazione significativa. I token sono i mattoni fondamentali che i modelli di IA utilizzano per elaborare e comprendere testi o altre sequenze di dati.

Tipologie di Token

1. **Token di parola:** Ogni parola in una frase è considerata un token. Ad esempio, nella frase "Il cane corre nel parco", i token sono: "Il", "cane", "corre", "nel", "parco".
2. **Token di sotto-parola:** Per lingue con morfologie complesse o vocabolari estesi, i modelli possono suddividere le parole in unità più piccole. Ad esempio, la parola "incredibile" potrebbe essere tokenizzata come "in", "credi", "bile".
3. **Token di carattere:** Ogni carattere è trattato come un token. Questo approccio è comune in lingue come il cinese, il giapponese e il coreano, dove le parole non sono separate da spazi.
4. **Token di codice:** Nel contesto della programmazione, i token rappresentano elementi come parole chiave, identificatori, operatori e costanti.

Perché i Token Sono Importanti?

La tokenizzazione permette ai modelli di IA di suddividere i dati complessi in unità gestibili, facilitando l'apprendimento di schemi e relazioni nei dati. Questo è essenziale per molte applicazioni come l'analisi del sentiment, la traduzione automatica e la generazione di testo.

Capitolo 2: La Finestra di Contesto

La finestra di contesto è un concetto fondamentale nell'IA, soprattutto nel campo dell'elaborazione del linguaggio naturale (NLP). Si riferisce al numero di parole o token che il modello considera intorno a un token target per comprenderne il significato.

Esempi di Finestra di Contesto

1. Frase: "La banca era chiusa per una rapina."
 - Token target: "banca"
 - Finestra di contesto (2 parole prima e 2 dopo): "La banca era chiusa"
 - Interpretazione: "banca" si riferisce probabilmente a un'istituzione finanziaria.
2. Frase: "Sono andato alla banca per depositare lo stipendio."
 - Token target: "banca"
 - Finestra di contesto: "alla banca per"
 - Interpretazione: Anche in questo caso, "banca" si riferisce a un'istituzione finanziaria.

3. Frase: "La riva del fiume era erosa dalla pioggia."

- Token target: "riva"
- Finestra di contesto: "del fiume era"
- Interpretazione: Qui, "riva" si riferisce al margine di un fiume.

Importanza della Finestra di Contesto

- Aiuta i modelli a disambiguare il significato delle parole.
- È cruciale in applicazioni come la traduzione automatica, l'analisi del sentiment e il riassunto di testi.
- La dimensione della finestra può essere regolata: finestre più ampie forniscono più informazioni ma possono introdurre rumore, mentre finestre più strette potrebbero non catturare abbastanza contesto.

Conclusione Comprendere i concetti di token e finestra di contesto è essenziale per chiunque voglia avvicinarsi al mondo dell'Intelligenza Artificiale e, in particolare, all'elaborazione del linguaggio naturale. Questi strumenti sono alla base di molti progressi tecnologici e applicazioni pratiche, rendendoli fondamentali per il successo di modelli e sistemi basati su IA.